Metodología automatizada para la consolidación de información profesional de egresados de la Facultad de Ingeniería a partir de LinkedIn

Juan David Cárdenas Galvis

Programa de Ingeniería de Sistemas y Computación, Facultad de Ingeniería,

Universidad Nacional de Colombia, Sede Bogotá

Prueba técnica para la vinculación

2 de noviembre de 2026

Tabla de contenido

Documento metodológico 3

Por qué esta propuesta 3

Identificación de egresados 5

Definición de variables 11

Recolección y consolidación 13

Calidad y trazabilidad 15

Protección de datos 17

Análisis 19

Implementación 21

Estructura de la base de datos 23

Diccionario de datos 23

Estructura de almacenamiento 29

Identificación de registros 31

Estandarización 32

Control de calidad 34

Datos de prueba 35

Referencias ..... **¡Error! Marcador no definido.**

Metodología automatizada para la consolidación de información profesional de egresados de la Facultad de Ingeniería a partir de LinkedIn

Este documento responde a las actividades 3.1 y 3.2 de la prueba técnica. Propone un proceso automatizado que encuentra en LinkedIn los perfiles de egresados de la Facultad de Ingeniería de la Universidad Nacional de Colombia, verifica que efectivamente lo sean, extrae y estandariza su trayectoria profesional, controla la calidad de los datos y los consolida en una base de datos relacional. El diseño parte de tres supuestos. Primero, la única fuente disponible es LinkedIn: no se cuenta con el registro de graduados de la Universidad, de modo que la población se construye a partir de los propios perfiles. Segundo, el proceso se ejecuta sin intervención humana, salvo en los casos que el mismo sistema envía a revisión alguna información de los perfiles. Tercero, la Facultad de Ingeniería es la de la Sede Bogotá. La implementación de referencia (esquema de la base de datos, proceso en Python y datos de prueba ficticios) se encuentra en el repositorio de GitHub que acompaña este documento. La información se obtiene por dos vías complementarias: el *web scraping* de los perfiles públicos de LinkedIn y la entrega de información por parte de los propios egresados a la Facultad.

Documento metodológico

Por qué esta propuesta

La propuesta resuelve el problema central del seguimiento a egresados: obtener información actualizada de toda la población sin depender de encuestas con baja respuesta ni de un registro previo de graduados. Sus fortalezas son las siguientes:

- **Cubre a toda la población.** El *web scraping* construye la población a partir de los perfiles públicos, de modo que no hace falta que cada egresado participe para conocer su

trayectoria. He de aclararse que si hace falta entonces que tenga un perfil en LinkedIn, con información que permita identificarlo como egresado de la Universidad.

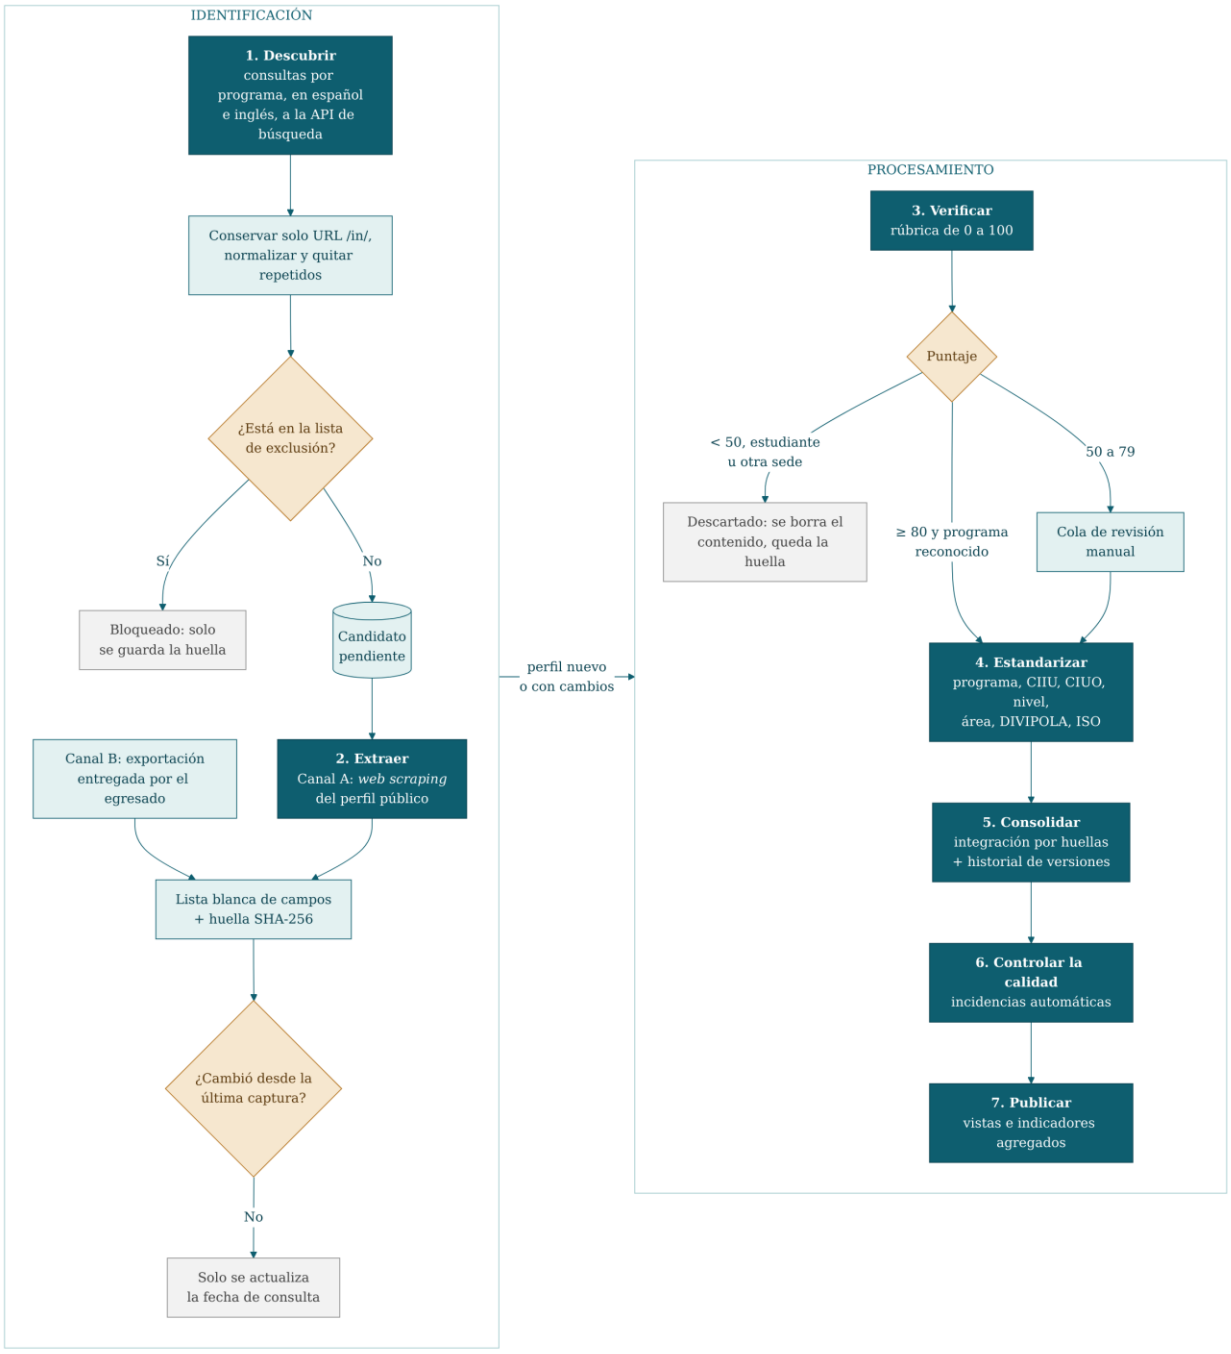
- **Combina alcance y precisión.** El *scraping* aporta cobertura y actualización frecuente. la información que entregan los egresados aporta los datos más completos y confiables, y completa lo que el primer canal no alcanza. Los dos canales producen el mismo formato, así que el resto del proceso es uno solo.
- **Es automática y reproducible.** Un mismo proceso programado descubre, extrae, verifica, estandariza y consolida los perfiles. Repetirlo no duplica registros, y cada dato conserva su fuente y la ejecución que lo produjo.
- **Controla la calidad desde el origen.** Una rúbrica decide qué perfiles pertenecen a la Facultad, la base de datos rechaza los valores inválidos y el sistema registra cada dato incompleto, ambiguo o desactualizado. La revisión humana se reserva para los casos dudosos.
- **Produce resultados comparables.** Clasifica la información con estándares oficiales (SNIES, CIIU, CIUO-08, DIVIPOLA e ISO 3166), por lo que los indicadores de la Facultad se pueden contrastar con las estadísticas nacionales.
- **Protege los datos desde el diseño.** Solo guarda las variables necesarias, borra el contenido de las capturas a los 90 días, publica únicamente cifras agregadas y respeta a quien pide no ser tratado.
- **Está probada.** La implementación de referencia funciona de principio a fin con datos ficticios y supera 20 pruebas de la base de datos y 25 pruebas unitarias.

Identificación de egresados

Como no existe una lista previa de egresados, la identificación tiene dos momentos: primero se *descubren* perfiles que podrían corresponder a egresados y después se *verifica* cada uno con una rúbrica automática. La Figura 1 muestra el proceso completo, desde la búsqueda hasta la publicación de indicadores.

Figura 1

Flujo del proceso automatizado de identificación, recolección y consolidación



Nota. Los números indican las etapas descritas en este documento. Las etapas 1 a 6 se ejecutan sin intervención humana; solo los perfiles con puntaje entre 50 y 79 y las incidencias de calidad pasan por revisión manual.

Estrategia de búsqueda

La búsqueda combina dos canales que entregan la información en un mismo formato, de modo que el resto del proceso no depende del origen de los datos.

Canal A: descubrimiento y extracción automáticos mediante *web scraping*. Es el canal principal. Se eligió el *web scraping* porque es la forma más efectiva de cubrir a toda la población:

- no depende de que el egresado participe, como el canal B.
- no tiene un costo por perfil.
- obtiene la versión más reciente de cada perfil.

Funciona en cuatro pasos:

1. *Generación de consultas.* A partir del catálogo de programas de la Facultad, el sistema genera dos consultas por programa, una en español y otra en inglés, porque muchos egresados escriben su perfil en inglés. Por ejemplo, `site:linkedin.com/in "Universidad Nacional de Colombia" "Ingeniería Civil"` y `site:linkedin.com/in "National University of Colombia" "Civil Engineering"`. Las consultas se envían a la API de un motor de búsqueda (Como Google,), que devuelve las páginas públicas indexadas sin necesidad de iniciar sesión en LinkedIn.
2. *Normalización de resultados.* De cada resultado solo se conservan las direcciones de perfiles personales (las que contienen `/in/`); las de publicaciones, empresas o grupos se ignoran. De la dirección se extrae el identificador público (por ejemplo, `ana-maria-rojas-perez`), en minúsculas, sin parámetros de seguimiento y sin el subdominio del país. Así, un mismo perfil encontrado por varias consultas se registra una sola vez.

3. *Cola de candidatos.* Cada identificador nuevo entra a la cola como candidato pendiente. Los perfiles ya evaluados no se vuelven a procesar, incluidos los descartados, de los que solo se guarda una huella cifrada.
4. *Extracción por web scraping.* Un módulo de *scraping* en Python descarga la versión pública de cada perfil candidato, es decir, la que LinkedIn muestra a un visitante sin sesión iniciada. Luego la analiza para obtener las secciones de experiencia y formación:
    - Primero lee los datos estructurados que la página publica para los buscadores (JSON-LD con el esquema `Person` de schema.org), cuando los incluye.
    - Si no los incluye, recorre el HTML con selectores (BeautifulSoup).
    - Si el contenido solo aparece después de ejecutar JavaScript, usa un navegador sin interfaz gráfica (Playwright).

    El analizador convierte el resultado al perfil canónico y, en ese mismo paso, descarta todo lo que no está en la lista blanca de campos.

    El *scraper* opera con cinco reglas:

- **Solo páginas públicas.** No inicia sesión, no usa cuentas y no accede a contenido restringido.
- **Ritmo bajo.** Hace una solicitud cada 10 a 20 segundos, tiene un límite diario de perfiles y trabaja en horario nocturno. Ante una respuesta de bloqueo o de límite de solicitudes, se detiene y reintenta al día siguiente.
- **Sin evasión de controles.** Si LinkedIn muestra un muro de inicio de sesión o un CAPTCHA, el perfil se marca como no disponible y se invita a su titular a usar el canal B. No se usan servicios para resolver CAPTCHA ni rotación de direcciones IP.

- **Identificación.** Se debe presentar con un agente de usuario que identifica a la Facultad e incluye un correo de contacto.
- **Detección de cambios.** El analizador tiene versión, y cada semana se prueba con perfiles de control. Si muchas páginas devuelven secciones vacías, la causa probable es que LinkedIn cambió la estructura de sus páginas. En ese caso la ejecución se marca como parcial y se avisa al analista para que ajuste los selectores.

Canal B: exportación entregada por el egresado. LinkedIn permite a cada usuario descargar una copia de sus datos. La Facultad invita a sus egresados, a través de su página en LinkedIn, a cargar ese archivo en un formulario con autorización expresa para el tratamiento. El proceso lee automáticamente tres tablas del archivo (perfil, cargos y formación) y descarta el resto. Este canal es el más confiable y el de mayor legitimidad, porque es el propio titular quien entrega la información. Además, permite completar perfiles que el canal A no encuentra, no puede leer o califica por debajo del umbral.

Criterios de verificación de correspondencia

La pertenencia a la Facultad se infiere de la sección «Educación» del perfil. El sistema califica cada entrada de formación con la rúbrica de la Tabla 1 y conserva la de mayor puntaje.

Tabla 1

Rúbrica de verificación de pertenencia a la Facultad

Criterio	Evidencia en el perfil	Puntos
Institución	Enlace a la página oficial de la Universidad en LinkedIn	35
	Nombre completo de la Universidad o su sigla (UNAL), en español o en inglés	30
	Solo «Universidad Nacional», sin país	10
Programa	El título o el campo de estudio coincide con un programa de la Facultad según el diccionario de homologación	30

Criterio	Evidencia en el perfil	Puntos
	Solo menciona «ingeniería», sin programa reconocible	10
Condición de egresado	Año de finalización igual o anterior al año en curso	15
	Título reconocible (Ingeniero, *Bachelor*, Magíster, etc.)	5
Sede	La formación o la residencia mencionan Bogotá	10
	No hay señal de ninguna sede	5
Coherencia	Duración plausible para el nivel: pregrado de 4 a 9 años, maestría de 1 a 5, doctorado de 3 a 8	5
Total		**100**

Nota. Los puntos de un mismo criterio no se suman: se asigna el de la evidencia más fuerte. Las expresiones que reconocen la institución, el programa y el nivel se guardan como datos en la base de datos y se pueden ampliar sin modificar el programa.

Los pesos reflejan el valor de cada evidencia. La institución y el programa suman 65 puntos porque son la prueba directa de pertenencia. La condición de egresado (20) distingue a quien terminó de quien todavía estudia. La sede pesa poco (10) porque muchos perfiles mencionan la Universidad sin indicar la sede. La coherencia (5) penaliza datos inconsistentes.

Con el puntaje se toma una de tres decisiones:

- **80 o más, con programa reconocido: aceptado automáticamente.** Sin programa reconocido no hay aceptación automática, aunque el puntaje llegue a 80.
- **Entre 50 y 79: revisión manual.** El perfil se consolida, pero queda fuera de los indicadores hasta que un analista lo confirme con la evidencia del perfil.
- **Menos de 50: descartado.** Se borra su contenido y solo se conserva una huella para no volver a evaluarlo.

Además, tres reglas excluyen el perfil sin importar el puntaje:

1. *Otra sede:* la formación menciona otra sede o facultad (Medellín, Facultad de Minas, Manizales, Palmira o las sedes de presencia nacional), porque esos egresados corresponden a otras facultades, aunque el nombre del programa coincida.

2. *Estudiante:* el año de finalización del programa es posterior al año en curso.
3. *Sin formación en la Universidad:* ninguna entrada de formación menciona a la Universidad.

La correspondencia con los programas curriculares se resuelve con el diccionario de homologación de programas. Este diccionario reconoce variantes en español e inglés, abreviaturas (Ing. Sistemas), los nombres que los programas tuvieron en el pasado y el nivel de formación. Primero se detecta el nivel a partir del título (por ejemplo, «Magíster en Ingeniería» corresponde a maestría) y luego solo se aplican las reglas de los programas de ese nivel. Así, «Ingeniería de Sistemas y Computación» se asigna al pregrado o a la maestría según el título.

Definición de variables

La Tabla 2 presenta las variables que se recopilan, la razón por la que se necesitan y la regla con la que se registran. Todas provienen de LinkedIn. Las variables que no aparecen en la tabla no se recopilan.

Tabla 2

Variables recopiladas, justificación y reglas de registro

Variable	Justificación	Regla de registro
Identificación del perfil		
Identificador público	Llave natural del egresado; permite volver a consultar el perfil	Segmento posterior a `/in/` en minúsculas, sin parámetros; de 3 a 100 caracteres (letras, números, guion)
Identificador interno (URN)	Se mantiene aunque el egresado cambie su URL	Se registra tal como lo entrega el canal; opcional y único
Nombres y apellidos	Detectar duplicados y facilitar la revisión manual; no se publican	Texto tal como aparece, sin espacios repetidos; se compara sin tildes ni mayúsculas
País y municipio de residencia	Medir la movilidad geográfica	País ISO 3166-1 alfa-2; municipio DIVIPOLA de 5 dígitos solo si el país es Colombia

Variable	Justificación	Regla de registro
Puntaje y criterios de pertenencia	Explicar por qué se aceptó el perfil	Entero de 0 a 100 y el puntaje de cada criterio de la rúbrica
Formación		
Institución, título y campo de estudio	Evidencia de pertenencia y de formación posterior	Texto original, sin modificar
Programa de la Facultad	Principal variable de desagregación	Código del catálogo de programas; vacío si la formación no es de la Facultad
Nivel de formación	Identificar posgrados	Categoría SNIES: tecnológico, pregrado, especialización, maestría, doctorado
Años de inicio y de finalización	Cohorte aproximada; distinguir estudiantes de egresados	Año de 4 dígitos; finalización igual o posterior al inicio; si es futura, se marca «en curso»
Experiencia laboral		
Cargo (texto original)	Base de la clasificación; permite reclasificar sin volver a consultar	Texto literal del perfil
Organización	Identificar empleadores	Nombre canónico en mayúsculas con sufijo societario normalizado; identificador de su página en LinkedIn
Industria y tipo de empresa	Asignar sector económico y naturaleza (pública, privada, emprendimiento)	Valor de la página de la empresa, homologado a CIIU y a tipo de organización
Ocupación, nivel jerárquico y área	Analizar ocupaciones, progresión y pertinencia	Derivadas del cargo: CIUO-08 A.C., 6 niveles ordinales y 18 áreas
Tipo de vínculo y modalidad	Caracterizar el empleo y el emprendimiento	Tiempo completo, medio tiempo, contrato, independiente, práctica, emprendimiento; presencial, híbrido, remoto
Fechas de inicio y fin	Duración, rotación y tiempo hasta el primer empleo	Fecha con precisión de mes o año; fin vacío si el cargo es actual; no se aceptan fechas futuras
Ubicación del cargo	Distribución geográfica del empleo	Igual que la residencia; se conserva además el texto original
Trazabilidad		
Canal, fecha y huella de la captura	Saber de dónde y cuándo salió cada dato	Código del canal, fecha y hora, SHA-256 del contenido
Ejecución del proceso	Reconstruir qué versión del proceso produjo el dato	Identificador de la ejecución con sus parámetros y resultados

Por el principio de minimización, el proceso no recopila la fotografía, el extracto (Acerca de), las aptitudes y validaciones, las recomendaciones, las publicaciones y la actividad, el número de contactos, los datos de contacto (correo, teléfono, dirección), la fecha de nacimiento,

las descripciones de los cargos ni las actividades estudiantiles. Tampoco infiere el sexo ni la edad a partir del nombre o de la fotografía. Estos campos se eliminan antes de guardar la captura, mediante una lista blanca de campos permitidos.

Recolección y consolidación

Procedimiento

El proceso se ejecuta por etapas programadas (véase la sección «Implementación»). Cada etapa es idempotente: se puede repetir sin duplicar información.

1. **Descubrir.** Genera las consultas, normaliza las direcciones y agrega los candidatos nuevos a la cola.
2. **Extraer.** Obtiene el perfil por el canal A o B y elimina los campos que no están en la lista blanca. Después calcula una huella SHA-256 del contenido y la compara con la de la captura anterior: si no cambió, solo se actualiza la fecha de la última consulta y no se reprocesa nada.
3. **Verificar.** Aplica la rúbrica y decide si el perfil se acepta, se envía a revisión o se descarta.
4. **Estandarizar.** Clasifica programa, nivel, sector, ocupación, nivel jerárquico, área, ubicación, vínculo y modalidad con los diccionarios de homologación.
5. **Consolidar.** Integra la información en las tablas de egresados, formación, organizaciones y experiencias.
6. **Controlar la calidad.** Detecta incidencias y cierra automáticamente las que ya se corrigieron.
7. **Publicar.** Actualiza las vistas y los indicadores agregados.

Cada ejecución queda registrada en una bitácora con sus parámetros, la versión del proceso y los resultados (perfiles leídos, nuevos, sin cambios, descartados y errores). Si un perfil falla, el proceso registra el error y continúa con el siguiente.

Integración de registros

Cada formación y cada experiencia tienen una huella que las identifica entre capturas sucesivas. La huella de la formación combina institución, título, campo y año de inicio; la de la experiencia combina organización, cargo y fecha de inicio. Cuando llega una nueva captura del mismo perfil, ocurre una de tres cosas:

- Si la huella ya existe, se actualizan sus datos; por ejemplo, se registra la fecha de fin de un cargo que terminó.
- Si la huella es nueva, se agrega la fila.
- Si una huella desapareció del perfil, la fila no se borra: se marca como «no vigente en la fuente» y sale del análisis.

La base de datos guarda cada versión anterior de las filas, de modo que siempre se puede reconstruir qué se sabía en una fecha dada. Las capturas de ambos canales que corresponden al mismo identificador público se integran en el mismo egresado.

Identificación de duplicados

- **Mismo perfil en varias consultas:** se resuelve en el descubrimiento, porque el identificador normalizado es único.
- **Cambio de URL:** si el canal entrega el identificador interno (URN), el perfil con la nueva URL se asocia al egresado existente.
- **Misma persona con dos cuentas:** el sistema marca como posible duplicado a dos egresados con el mismo nombre (comparado sin tildes, sin mayúsculas), el mismo

programa y una cohorte con diferencia de un año o menos. Un analista confirma el caso y un procedimiento de fusión une los registros sin perder su historia.

- **Organizaciones:** se identifican, en este orden, por su página de LinkedIn, por los alias ya conocidos y por el nombre sin sufijo societario («Andes Software» y «ANDES SOFTWARE S.A.S.» son la misma organización). Las variantes mal escritas se detectan con una clave fonética («DATALITICA» y «DATALYTICA») y se envían a revisión.

Estandarización de categorías

Todas las variables categóricas se clasifican automáticamente con diccionarios guardados en la base de datos: expresiones regulares con prioridad, tablas de equivalencia y un nomenclátor de ubicaciones. Las categorías y las reglas se detallan en la sección «Estandarización» de la estructura de la base de datos. Cuando ninguna regla aplica, el campo queda vacío, se genera una incidencia y el analista lo clasifica a mano. Esa clasificación se marca como manual y el proceso nunca la sobrescribe. Además, cada caso resuelto a mano se convierte en una regla nueva, de modo que la clasificación automática mejora con el tiempo.

Documentación de las fuentes

Cada dato consolidado apunta a la captura que lo respalda. La captura registra el canal (con su nivel de confiabilidad), la fecha y hora, la huella del contenido y la ejecución que la produjo. El contenido de la captura se conserva 90 días para auditoría y luego se elimina; la huella y los metadatos se conservan.

Calidad y trazabilidad

El sistema revisa la calidad en cada ejecución con reglas automáticas que generan incidencias. La Tabla 3 muestra cómo se detecta y se trata cada tipo de problema.

Tabla 3

Detección y tratamiento de problemas de calidad

Problema	Regla automática de detección	Tratamiento
Información incompleta	Cargo sin ocupación, nivel o área; organización sin sector; ubicación no reconocida; experiencia sin fecha de inicio	Revisión manual y nueva regla en el diccionario; la incidencia se cierra sola cuando el dato se completa
Información ambigua	Pertenencia con puntaje entre 50 y 79; perfil aceptado cuya nueva captura ya no confirma la pertenencia	Cola de revisión manual; el perfil no entra a los indicadores mientras tanto
Información desactualizada	Última captura con más de 12 meses	Prioridad en la siguiente extracción; la incidencia se cierra sola al actualizarse
Información no verificable	Formación de la Facultad sin años; perfil que deja de estar disponible después de dos intentos	Se excluye de los indicadores que dependen del dato faltante
Posible duplicado	Egresados con el mismo nombre, programa y cohorte; organizaciones con la misma clave fonética	Confirmación del analista y fusión
Inconsistencia	Fechas imposibles; empleo de tiempo completo iniciado más de dos años antes de terminar el programa; más de dos cargos actuales	Revisión manual del perfil

Cada incidencia pasa por los estados abierta, en revisión, resuelta o descartada, y registra quién la cerró y cuándo. La detección es idempotente, de modo que una incidencia ya registrada no se duplica en ejecuciones posteriores. Para seguir la calidad en el tiempo se calculan cinco indicadores:

- porcentaje de experiencias clasificadas automáticamente;
- tamaño de la cola de revisión manual;
- porcentaje de perfiles desactualizados;
- completitud por variable;
- errores por ejecución.

La trazabilidad se garantiza en cuatro niveles:

1. **Dato:** cada formación y experiencia referencia la captura que la respalda.

2. **Versión:** las tablas de formación y experiencia guardan automáticamente cada versión anterior, con su periodo de vigencia (*system versioning* de MariaDB). Por ejemplo, el historial de una experiencia muestra cómo la homologación le asignó ocupación, nivel y área.
3. **Proceso:** la bitácora registra cada ejecución, su versión y sus parámetros.
4. **Decisión humana:** las verificaciones y clasificaciones manuales registran al responsable y se distinguen de las automáticas.

Protección de datos

Minimización de datos personales

- Solo se guardan los campos de la lista blanca (Tabla 2); el resto se elimina antes de almacenar la captura.
- De las personas que no son egresadas de la Facultad (estudiantes, egresados de otras sedes, perfiles descartados) no se conserva la URL ni el contenido, solo una huella SHA-256 que evita volver a procesarlas.
- El contenido de las capturas se borra automáticamente a los 90 días; los datos consolidados conservan únicamente las variables definidas.
- Los nombres solo los ven los analistas. Los informes y la API pública presentan cifras agregadas y ocultan cualquier grupo de menos de cinco personas para evitar que alguien sea identificado.

Acceso legítimo a la información

- **Solo información pública.** El *scraper* obtiene únicamente la información que LinkedIn muestra a cualquier visitante. No inicia sesión ni usa cuentas falsas. Tampoco evade

controles técnicos como muros de inicio de sesión, CAPTCHA o bloqueos, y mantiene un ritmo de solicitudes que no afecta el servicio.

- **Sin terceros.** El *scraping* lo ejecuta la propia Universidad en sus servidores, de modo que ningún tercero recibe los datos.
- **Autorización del titular.** En el canal B, el egresado entrega sus propios datos y otorga una autorización previa, expresa e informada.

Cumplimiento de las normas aplicables

El tratamiento se rige por la Ley 1581 de 2012 y su reglamentación, compilada en el Decreto 1074 de 2015.La Tabla 4 muestra cómo el diseño aplica cada principio de la ley.

Tabla 4

Aplicación de los principios de la Ley 1581 de 2012. Tabla realizada con ayuda de IA.

Principio (Ley 1581, art. 4)	Aplicación en el proceso
Legalidad	Tratamiento ajustado a la Ley 1581 y su reglamentación; registro de la base de datos en el Registro Nacional de Bases de Datos
Finalidad	Uso exclusivo para seguimiento de egresados, estadística y mejoramiento de la calidad académica, declarado en el aviso de privacidad; no se usa con fines comerciales
Libertad	Autorización expresa en el canal B; lista de exclusión que bloquea a quien se oponga
Veracidad o calidad	Rúbrica de verificación, reglas de validación, incidencias y actualización periódica
Transparencia	Aviso de privacidad en la página de la Facultad en LinkedIn y en su sitio web; canal para consultas y reclamos
Acceso y circulación restringida	Roles con mínimo privilegio; los informes solo presentan cifras agregadas
Seguridad	Cifrado en tránsito y en reposo, copias de respaldo, registro de accesos, usuarios sin permiso de borrado
Confidencialidad	Compromiso de confidencialidad de quienes operan el sistema; los datos no se entregan a terceros

Fundamento del canal A. El canal A trata información que el propio egresado publicó en su perfil profesional. Se apoya en dos excepciones del artículo 10 de la Ley 1581: la

información requerida por una entidad pública en ejercicio de sus funciones legales y el tratamiento con fines estadísticos o científicos. Además, el seguimiento a egresados es una condición de calidad exigida a las instituciones de educación superior (Ministerio de Educación Nacional, 2019; Consejo Nacional de Educación Superior [CESU], 2020) y la profesión u oficio se considera dato público (Presidencia de la República de Colombia, 2013, art. 3). Se cumplen, además, los demás deberes de la ley:

- **Aviso de privacidad:** se publica en la página de la Facultad en LinkedIn y en su sitio web. Indica quién es el responsable, qué datos se tratan, con qué finalidad, qué derechos tiene el titular y cómo ejercerlos.
- **Derechos del titular:** los derechos de consulta, actualización, rectificación, supresión y oposición (art. 8) se atienden en los plazos de la ley: 10 días hábiles para consultas y 15 para reclamos (arts. 14 y 15). La supresión se ejecuta con un procedimiento que borra los datos consolidados y agrega el perfil a la lista de exclusión, para que el proceso automático no lo vuelva a capturar.
- **Sin transferencia internacional:** el *scraper* y la base de datos funcionan en servidores de la Universidad. La información no se comparte con terceros ni se envía fuera del país (Congreso de la República de Colombia, 2012, art. 26).
- **Retención:** el contenido de las capturas se borra a los 90 días; los datos consolidados se conservan mientras se mantenga la finalidad; el historial de versiones se depura cada año y conserva como máximo cinco años.

Análisis

La Tabla 5 presenta las preguntas que la Facultad podría responder con la información consolidada y el indicador correspondiente. Todos se pueden desagregar por programa, cohorte

(año de finalización) y nivel de formación. El repositorio incluye las consultas SQL que los calculan.

Tabla 5

Preguntas de análisis e indicadores

Pregunta	Indicador
¿Cuántos egresados de cada programa y cohorte se identificaron?	Tasa de identificación: egresados aceptados / graduados reportados por el SNIES y el Observatorio Laboral para la Educación
¿En qué sectores económicos trabajan?	Distribución por sección CIIU del cargo actual
¿En qué ocupaciones y áreas se desempeñan?	Distribución por grupo CIUO y por área de desempeño
¿El trabajo corresponde a su formación?	Pertinencia: porcentaje en áreas que el comité de cada programa define como afines
¿Cuánto tardan en conseguir empleo?	Años entre la finalización y el primer empleo (sin prácticas); porcentaje vinculado durante el primer año
¿Cómo progresan en su carrera?	Nivel jerárquico promedio según los años transcurridos desde la finalización; tiempo hasta un cargo de coordinación o gerencia
¿Dónde trabajan?	Porcentaje en el exterior por país; distribución por departamento y municipio
¿Trabajan en el sector público, en el privado o emprenden?	Distribución por tipo de organización; porcentaje de fundadores
¿Continúan estudiando?	Porcentaje con posgrado, en la Facultad o en otra institución, en Colombia o en el exterior
¿Qué organizaciones los contratan?	Principales empleadores por número de egresados
¿Qué tan estables son sus empleos?	Duración promedio de los empleos; número de empleadores en los primeros cinco años
¿Qué tan confiable es la información?	Cobertura, porcentaje de aceptación automática, completitud y porcentaje desactualizado

Para interpretar estos indicadores hay que tener en cuenta dos limitaciones:

- **Sesgo de selección.** LinkedIn no representa a toda la población: tiene más presencia de algunas áreas (por ejemplo, tecnología) y de las cohortes recientes. Por eso cada indicador se publica junto con su tasa de identificación y no se generaliza a programas o cohortes con baja cobertura.

- **Datos autodeclarados.** El egresado escribe su propio perfil y no siempre lo mantiene al día. Los resultados deben contrastarse periódicamente con el Observatorio Laboral para la Educación.

Implementación

Actividades

La implementación se organiza en cinco fases (Tabla 6). Las fases 1 y 2 se ejecutan en paralelo durante dos semanas.

Tabla 6

Fases y actividades de la implementación

Fase	Actividades	Semanas	Producto
1. Preparación	Aviso de privacidad; API de búsqueda; servidor; procesos administrativos	1–3	Condiciones listas para operar
2. Construcción	Despliegue de la base de datos y del proceso; desarrollo del módulo de *scraping* y de su analizador con perfiles de control; carga de catálogos y diccionarios; pruebas automáticas	2–5	Sistema probado con datos ficticios
3. Piloto	Ejecución con dos programas; revisión manual de una muestra aleatoria de 100 perfiles para medir la precisión de la rúbrica (meta: 95 % en las aceptaciones automáticas); ajuste de umbrales y diccionarios; porcentaje de perfiles que el *scraper* lee con éxito	6–9	Informe del piloto y parámetros calibrados
4. Despliegue	Extensión a todos los programas; programación de las tareas; formulario del canal B; tablero de indicadores; capacitación	10–12	Proceso en producción
5. Operación	Ejecuciones automáticas; revisión de la cola manual; informes; revisión anual de la metodología	Continua	Base actualizada e informes periódicos

Recursos

Humanos.

- Un coordinador, profesor o profesional de la Facultad, con una dedicación de cuatro horas semanales.

- Un estudiante auxiliar con formación en datos: entre 10 y 20 horas semanales durante la construcción y el piloto, y entre 4 y 6 horas semanales en la operación (cola de revisión y diccionarios).
- Apoyo puntual de la Oficina Jurídica y de la dependencia de tecnología de la sede.

Técnicos.

- Una máquina virtual con Ubuntu Server 24.04 LTS (2 v CPU, 4 GB de RAM y 50 GB de disco).
- MariaDB 11.4 LTS y Python 3.12 con Django; Requests, BeautifulSoup y Playwright para el *scraping*.
- Copias de respaldo diarias.
- El repositorio de GitHub con el código y la documentación.

Todo el software es libre.

Responsables

La Tabla 7 asigna las responsabilidades de cada rol, que coinciden con los permisos que tiene en la base de datos.

Tabla 7

Roles y responsabilidades

Rol	Responsabilidades
Decanatura	Aprueba la metodología, el uso de la información y los informes
Coordinador de seguimiento a egresados	Dirige la implementación; publica los informes; atiende, junto con el oficial de datos, las solicitudes de los titulares
Analista de datos (estudiante auxiliar)	Opera el proceso; mantiene el analizador del *scraper*; revisa la cola manual; resuelve incidencias; mantiene los diccionarios; fusiona duplicados
Oficial de protección de datos (Oficina Jurídica)	Aprueba el aviso de privacidad; ejecuta las supresiones; vigila el cumplimiento

Rol	Responsabilidades
Administrador de tecnología	Mantiene el servidor, las copias de respaldo, los accesos y la programación de tareas

Mecanismos de actualización periódica

Las tareas se programan en el servidor (cron) y en el planificador de eventos de MariaDB. La Tabla 8 muestra su frecuencia.

Tabla 8

Mecanismos de actualización periódica

Tarea	Frecuencia	Mecanismo
Descubrir perfiles nuevos	Semanal	Proceso automático (cron)
Extraer perfiles en lotes, empezando por los más antiguos; cada perfil se renueva cada 90 días	Diaria	Proceso automático (cron)
Procesar, homologar y detectar incidencias	Diaria, después de la extracción	Proceso automático (cron)
Probar el analizador del *scraper* con perfiles de control	Semanal	Proceso automático; alerta al analista si falla
Borrar el contenido de las capturas vencidas	Diaria	Evento de MariaDB
Copias de respaldo	Diaria	Tarea del servidor
Revisar la cola manual y las incidencias	Semanal	Analista
Agregar reglas a los diccionarios	Mensual	Analista
Búsqueda adicional de la nueva cohorte	Después de cada ceremonia de grados	Ejecución manual del proceso
Informe de indicadores	Semestral	Coordinador
Depurar el historial de versiones y revisar umbrales y metodología	Anual	Coordinador y analista

Estructura de la base de datos

Diccionario de datos

Las tablas siguientes describen cada variable de las tablas principales. En la columna *Obl.* (obligatoriedad), «Sí» indica que el campo no admite valores vacíos y «Cond.» que es

obligatorio solo en el caso indicado. La columna *Validación* nombra la regla de la base de datos que la aplica: restricciones de verificación (CHECK), llaves foráneas (FK), llaves únicas (UNIQUE) o disparadores (*triggers*).

Tabla 9

Diccionario de datos de la tabla egresado

Variable	Descripción	Tipo	Formato	Obl.	Validación
id_egresado	Llave primaria sustituta	INT	Autonumérico	Sí	PK
id_candidato	Candidato del que proviene	INT	Entero	Sí	FK; UNIQUE
id_publico_linkedin	Identificador público del perfil	VARCHAR(100)	`[a-z0-9%_-]`	Sí	CHECK de formato; UNIQUE
urn_linkedin	Identificador interno estable	VARCHAR(60)	Texto	No	UNIQUE
url_perfil	URL del perfil (calculada)	VARCHAR(140)	URL	Sí	Columna generada
nombres	Nombres	VARCHAR(100)	Texto	Sí	No vacío
apellidos	Apellidos	VARCHAR(100)	Texto	No	—
nombre_completo	Nombre en mayúsculas (calculado)	VARCHAR(201)	Texto	Sí	Columna generada
codigo_pais_residencia	País de residencia	CHAR(2)	ISO 3166-1	No	FK
codigo_municipio_residencia	Municipio de residencia	CHAR(5)	DIVIPOLA	Cond.	FK; solo si el país es CO
puntaje_pertenencia	Resultado de la rúbrica	TINYINT	0 a 100	Sí	CHECK ≤ 100
criterios_pertenencia	Puntaje por criterio	JSON	Objeto	Sí	CHECK JSON válido
estado_verificacion	Decisión de pertenencia	ENUM	ACEPTADO, POR_REVISAR	Sí	CHECK: aceptado ≥ 80 o manual; revisión ≥ 50
metodo_verificacion	Quién decidió	ENUM	AUTOMATICO, MANUAL	Sí	CHECK: manual exige responsable
verificado_por	Responsable de la decisión manual	VARCHAR(60)	Usuario	Cond.	—
estado_registro	Situación del registro	ENUM	ACTIVO, FUSIONADO, NO_DISPONIBLE	Sí	CHECK: fusionado exige destino

Variable	Descripción	Tipo	Formato	Obl.	Validación
id_egresado_destino	Registro que reemplaza a un duplicado	INT	Entero	Cond.	FK
id_ultima_captura	Última captura procesada	INT	Entero	Sí	FK
primera_captura_en, ultima_captura_en	Primera y última consulta	DATETIME	AAAA-MM-DD hh:mm	Sí	CHECK: última ≥ primera

Tabla 10

Diccionario de datos de la tabla formacion

Variable	Descripción	Tipo	Formato	Obl.	Validación
id_formacion	Llave primaria	INT	Autonumérico	Sí	PK
id_egresado	Egresado	INT	Entero	Sí	FK
id_captura	Captura que respalda el dato	INT	Entero	Sí	FK; *trigger*: misma persona
huella	Identidad entre capturas	CHAR(40)	SHA-1 hexadecimal	Sí	CHECK; UNIQUE por egresado
institucion_original	Institución, texto literal	VARCHAR(200)	Texto	Sí	—
titulo_original, campo_original	Título y campo de estudio	VARCHAR(200)	Texto	No	—
es_facultad	Programa de la Facultad	BOOLEAN	0/1	Sí	CHECK: equivale a tener programa
id_programa	Programa homologado	SMALLINT	Código	Cond.	FK al catálogo
codigo_nivel	Nivel de formación	VARCHAR(20)	Catálogo SNIES	No	FK
anio_inicio, anio_fin	Años de inicio y de finalización	SMALLINT	AAAA	No	CHECK 1940–2100; fin ≥ inicio; *trigger*: no futuro en la Facultad
en_curso	Formación no terminada	BOOLEAN	0/1	Sí	—
vigente_en_fuente	Sigue apareciendo en el perfil	BOOLEAN	0/1	Sí	—

Tabla 11

Diccionario de datos de la tabla experiencia_laboral

Variable	Descripción	Tipo	Formato	Obl.	Validación
id_experiencia	Llave primaria	INT	Autonumérico	Sí	PK

Variable	Descripción	Tipo	Formato	Obl.	Validación
id_egresado, id_organizacion	Egresado y organización	INT	Entero	Sí	FK
id_captura	Captura que respalda el dato	INT	Entero	Sí	FK; *trigger*: misma persona
huella	Identidad entre capturas	CHAR(40)	SHA-1 hexadecimal	Sí	CHECK; UNIQUE por egresado
cargo_original	Cargo, texto literal	VARCHAR(200)	Texto	Sí	—
codigo_ciuo	Ocupación	VARCHAR(4)	CIUO-08 A.C.	No	FK
codigo_nivel_cargo	Nivel jerárquico	VARCHAR(20)	Catálogo	No	FK
codigo_area	Área de desempeño	VARCHAR(30)	Catálogo	No	FK
metodo_clasificacion	Clasificación automática o manual	ENUM	AUTOMATICA, MANUAL	Sí	La manual no se sobrescribe
tipo_vinculo	Tipo de vínculo	ENUM	7 categorías	Sí	Valores del ENUM
modalidad	Modalidad de trabajo	ENUM	PRESENCIAL, HIBRIDO, REMOTO, NO_INFORMADO	Sí	Valores del ENUM
fecha_inicio	Inicio del cargo	DATE	AAAA-MM-01	Sí	*Trigger*: no futura
precision_inicio, precision_fin	Precisión de las fechas	ENUM	MES, ANIO	Cond.	CHECK: precisión de fin solo si hay fecha de fin
fecha_fin	Fin del cargo	DATE	AAAA-MM-01	Cond.	CHECK: ≥ inicio; vacía si es actual
es_actual	Cargo vigente	BOOLEAN	0/1	Sí	CHECK: actual sin fecha de fin
ubicacion_original	Ubicación, texto literal	VARCHAR(150)	Texto	No	—
codigo_pais	País del cargo	CHAR(2)	ISO 3166-1	No	FK
codigo_municipio	Municipio del cargo	CHAR(5)	DIVIPOLA	Cond.	FK; CHECK: solo si el país es CO
ciudad_extranjera	Ciudad fuera de Colombia	VARCHAR(100)	Texto	Cond.	CHECK: solo si el país no es CO
vigente_en_fuente	Sigue apareciendo en el perfil	BOOLEAN	0/1	Sí	—

Tabla 12

Diccionario de datos de las tablas organizacion y organizacion_alias

Variable	Descripción	Tipo	Formato	Obl.	Validación
id_organizacion	Llave primaria	INT	Autonumérico	Sí	PK

Variable	Descripción	Tipo	Formato	Obl.	Validación
nombre_normalizado	Nombre canónico	VARCHAR(200)	Mayúsculas con sufijo normalizado	Sí	UNIQUE (sin distinguir tildes)
id_linkedin_empresa	Identificador de la página de la empresa	VARCHAR(100)	`[a-z0-9%_-]`	No	CHECK de formato; UNIQUE
industria_linkedin	Industria según LinkedIn	VARCHAR(120)	Texto	No	—
codigo_seccion_ciiu	Sector económico	CHAR(1)	Letra A–U	No	FK; CHECK
codigo_tipo	Naturaleza de la organización	VARCHAR(20)	Catálogo	No	FK
organizacion_alias.alias	Variante del nombre encontrada en un perfil	VARCHAR(200)	Mayúsculas sin tildes	Sí	PK

Tabla 13

Diccionario de datos de las tablas de control del proceso

Variable	Descripción	Tipo	Formato	Obl.	Validación
candidato					
hash_id_publico	Huella del identificador público	CHAR(64)	SHA-256 hexadecimal	Sí	CHECK; UNIQUE
id_publico_linkedin	Identificador público	VARCHAR(100)	`[a-z0-9%_-]`	Cond.	CHECK: vacío si se descarta o excluye
consulta_origen	Consulta que lo encontró	VARCHAR(300)	Texto	No	—
estado, motivo_estado	Situación en la cola	ENUM	PENDIENTE, EXTRAIDO, DESCARTADO, EXCLUIDO, NO_DISPONIBLE	Sí	Valores del ENUM
intentos_fallidos	Intentos sin respuesta	TINYINT	Entero	Sí	—
captura					
id_candidato, id_ejecucion	Perfil y ejecución	INT	Entero	Sí	FK
codigo_canal	Canal de obtención	VARCHAR(30)	Catálogo	Sí	FK
capturada_en	Fecha y hora de la consulta	DATETIME	AAAA-MM-DD hh:mm	Sí	*Trigger*: no futura ni en lista de exclusión
hash_contenido	Huella del contenido	CHAR(64)	SHA-256 hexadecimal	Sí	CHECK
contenido	Campos de la lista blanca	JSON	Objeto	Cond.	CHECK JSON válido; se borra a los 90 días

Variable	Descripción	Tipo	Formato	Obl.	Validación
expira_en	Fecha de borrado del contenido	DATE	AAAA-MM-DD	Sí	CHECK: posterior a la captura
resultado, procesada	Comparación con la captura anterior y estado	ENUM, BOOLEAN	NUEVO, CON_CAMBIOS, SIN_CAMBIOS, DESCARTADO	Sí	Valores del ENUM
lista_exclusion					
hash_id_publico	Huella del perfil excluido	CHAR(64)	SHA-256 hexadecimal	Sí	PK; CHECK
motivo, radicado	Tipo de solicitud y su número	ENUM, VARCHAR(30)	SUPRESION, OPOSICION, REVOCATORIA	Sí	Valores del ENUM

Tabla 14

Diccionario de datos de las tablas de calidad y bitácora

Variable	Descripción	Tipo	Formato	Obl.	Validación
incidencia_calidad					
codigo_tipo	Tipo de incidencia	VARCHAR(30)	Catálogo	Sí	FK
entidad, id_registro	Tabla y registro afectados	VARCHAR(40), INT	Texto, entero	Sí	UNIQUE con el tipo (idempotencia)
descripcion	Detalle legible	VARCHAR(500)	Texto	Sí	—
estado	Ciclo de vida	ENUM	ABIERTA, EN_REVISION, RESUELTA, DESCARTADA	Sí	CHECK: el cierre exige responsable
detectada_en, resuelta_en, resuelta_por	Fechas y responsable	TIMESTAMP, VARCHAR	AAAA-MM-DD hh:mm	Cond.	—
ejecucion					
etapa, codigo_canal, version_proceso	Qué se ejecutó y con qué versión	ENUM, VARCHAR	Texto	Sí	FK al canal
parametros	Parámetros de la ejecución	JSON	Objeto	No	CHECK JSON válido
iniciada_en, finalizada_en, estado	Duración y resultado	DATETIME, ENUM	EXITOSA, PARCIAL, FALLIDA	Sí	CHECK: fin ≥ inicio
registros_leidos, nuevos, sin_cambio, descartados, errores	Contadores	INT	Entero	Sí	—

Estructura de almacenamiento

La información se almacena en una base de datos relacional en MariaDB 11.4 LTS, organizada en cuatro zonas (Tabla 15). La Figura 2 muestra las entidades principales y sus relaciones.

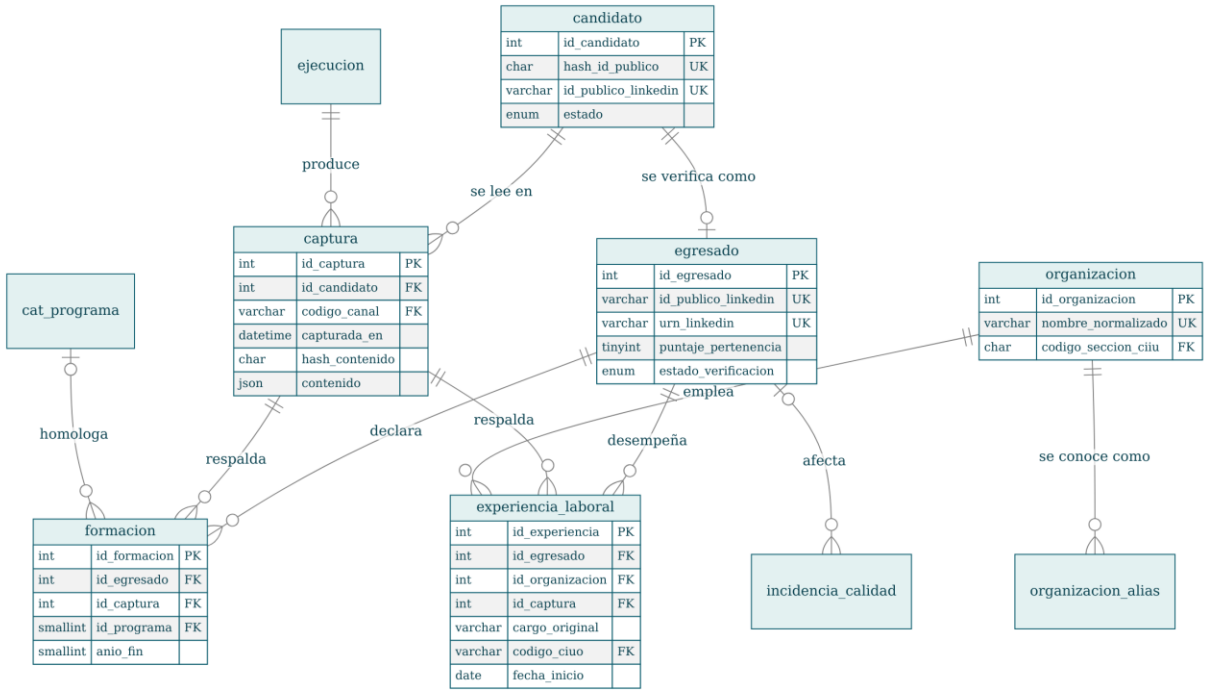
Tabla 15

Zonas de almacenamiento

Zona	Tablas	Propósito
Catálogos y diccionarios	Programas, niveles, CIIU, CIUO, niveles de cargo, áreas, tipos de organización, países, departamentos, municipios, canales, tipos de incidencia; reglas de institución, programa, nivel y cargo; equivalencias de industria y tipo de empresa; nomenclátor de ubicaciones	Estandarizar; se modifican sin cambiar el programa
Control del proceso	ejecucion, candidato, captura, lista_exclusion	Operar la automatización y documentar las fuentes
Consolidada	egresado, formacion, organizacion, organizacion_alias, experiencia_laboral	Información depurada y versionada
Calidad y consulta	incidencia_calidad; vistas de trayectoria, situación actual, egresado-programa, completitud, duplicados y resumen de calidad	Control de calidad y análisis

Figura 2

Modelo entidad-relación de las tablas principales



Nota. PK = llave primaria; FK = llave foránea; UK = llave única. Por legibilidad se omiten los catálogos de estandarización.

Justificación de la elección tecnológica. La Tabla 16 compara las alternativas que menciona la prueba con los requisitos de la metodología.

Tabla 16

Comparación de alternativas de almacenamiento

Requisito	Hoja de cálculo	Archivos estructurados (JSON/CSV)	Base de datos relacional (MariaDB)
Relaciones persona, formación, experiencia y organización	Manuales, con riesgo de error	Anidadas, con datos repetidos	Nativas, con integridad referencial
Validación de datos	Limitada, fácil de omitir	Depende del programa	Restricciones y disparadores que nadie puede omitir
Catálogos estándar	Listas desplegables frágiles	Sin integridad	Llaves foráneas

Requisito	Hoja de cálculo	Archivos estructurados (JSON/CSV)	Base de datos relacional (MariaDB)
Historial de cambios	No existe	Hay que programarlo	Tablas versionadas por el sistema
Escritura automática y concurrente	Conflictos de edición	Sin transacciones	Transacciones ACID
Control de acceso	Por archivo	Por archivo	Roles y permisos por tabla y vista
Análisis	Tablas dinámicas	Requiere programación	SQL, vistas y funciones de ventana

Se eligió MariaDB por cuatro razones:

- Es software libre, con versión de soporte extendido (LTS), y funciona de forma nativa en Ubuntu Server.
- Es compatible con el ecosistema MySQL y con Django.
- Ofrece tablas versionadas por el sistema, que resuelven la trazabilidad sin código adicional.
- Su planificador de eventos ejecuta la purga de capturas dentro de la propia base de datos.

Las hojas de cálculo siguen siendo útiles para exportar informes, pero no como sistema de registro.

Identificación de registros

Llave única del egresado. El egresado tiene tres llaves con funciones distintas:

- **Llave primaria sustituta (`id_egresado`).** Es un número sin significado y estable. Todas las tablas apuntan a ella, de modo que un cambio en el nombre o en la URL no rompe ninguna relación.
- **Llave natural única (`id_publico_linkedin`).** Garantiza que un perfil corresponda a un solo egresado y permite volver a consultarlo.

- **Llave alterna estable (`urn_linkedin`).** Cuando el canal la entrega, permite reconocer al mismo miembro aunque cambie su URL.

No se usa el nombre como llave porque no es único ni estable, ni el documento de identidad porque LinkedIn no lo publica y la metodología no lo necesita.

Relación entre personas, formación y experiencias. Un egresado tiene muchas formaciones y muchas experiencias (relaciones 1:N). La relación entre egresados y programas es N:M y se resuelve con la tabla de formación: un egresado puede tener un pregrado y una maestría de la Facultad, y un programa tiene muchos egresados. Cada experiencia se asocia a una organización normalizada, que a su vez tiene muchas experiencias. Cada formación y cada experiencia se asocian también a la captura que las respalda, y un disparador verifica que esa captura corresponda al mismo perfil. Las huellas descritas en la sección «Integración de registros» identifican la misma formación o experiencia entre capturas. Cuando dos registros resultan ser la misma persona, el procedimiento de fusión traslada las filas al registro que se conserva y marca el otro como fusionado, sin borrar su historia.

Estandarización

La Tabla 17 resume las categorías comunes, el estándar de referencia y la regla automática que se aplica a cada dimensión.

Tabla 17

Categorías comunes y reglas de estandarización

Dimensión	Estándar o categoría	Regla automática	Ejemplo
Programa curricular	Catálogo de programas de la Facultad, con código SNIES	Expresiones regulares sobre título y campo, filtradas por nivel	«Bachelor of Science» + «Chemical Engineering» → Ingeniería Química

Dimensión	Estándar o categoría	Regla automática	Ejemplo
Nivel de formación	Niveles del SNIES	Expresiones regulares sobre el título	«Magíster en Ingeniería» → Maestría
Sector económico	Secciones de la CIIU Rev. 4 A.C. (DANE, 2012)	Equivalencia entre la industria de LinkedIn y la sección	«Utilities» → D, Suministro de electricidad y gas
Naturaleza de la organización	Privada, pública, mixta, académica, ONG, multilateral, propia	Equivalencia con el tipo de empresa de LinkedIn	«Government Agency» → Entidad pública
Ocupación	CIUO-08 A.C. (DANE, s.f.-a; OIT, 2012)	Expresiones regulares con prioridad sobre el cargo	«Director de proyectos de infraestructura vial» → 1323
Nivel jerárquico	Seis niveles ordinales (propios)	Expresiones regulares con prioridad	«Ingeniera de datos sénior» → Profesional sénior
Área de desempeño	18 áreas funcionales (propias)	Expresiones regulares con prioridad	«Senior Process Engineer» → Producción y operaciones
Ubicación	ISO 3166-1 alfa-2 (ISO, 2020) y DIVIPOLA (DANE, s.f.-b)	Nomenclátor en español e inglés	«Hamburgo, Alemania» → DE, Hamburgo
Vínculo y modalidad	Categorías de LinkedIn agrupadas	Tabla de equivalencias	«Internship» → Práctica; «Remote» → Remoto

Nota. La clasificación del sector se hace sobre la organización, no sobre la persona.

El nivel jerárquico es ordinal, lo que permite medir la progresión (Tabla 18). Las 18 áreas de desempeño son: desarrollo de software; datos y analítica; infraestructura de TI; gestión de proyectos; producción y operaciones; calidad; logística; mantenimiento; diseño de ingeniería; construcción e interventoría; energía; ambiental; consultoría; comercial técnico; finanzas y riesgo; investigación y docencia; dirección general y emprendimiento; otra.

Tabla 18

Niveles jerárquicos del cargo

Orden	Nivel	Palabras clave (ejemplos)
1	Practicante	practicante, pasante, *intern*, aprendiz
2	Profesional	ingeniero, analista, desarrollador, *engineer*

Orden	Nivel	Palabras clave (ejemplos)
3	Profesional sénior	sénior, especialista, líder técnico, *principal*
4	Coordinación	coordinador, jefe, *team lead*
5	Gerencia	gerente, director, *manager*, *head of*
6	Alta dirección	CEO, CTO, fundador, presidente

Las reglas se aplican por dimensión: para cada una gana la regla de menor prioridad que coincida. Así, «Director de proyectos» obtiene el nivel de gerencia, la ocupación 1323 y el área de proyectos aunque cada dato provenga de una regla distinta.

Control de calidad

Detección de duplicados. Se aplica en cuatro niveles:

- Identificador público único en la cola de candidatos y en la tabla de egresados.
- Identificador interno (URN) para reconocer los cambios de URL.
- Una vista que compara nombre, programa y cohorte para detectar a la misma persona con dos cuentas.
- Una vista con clave fonética para detectar organizaciones repetidas.

Los dos últimos generan incidencias de posible duplicado, que se resuelven con el procedimiento de fusión.

Validación de campos. Las reglas están dentro de la base de datos, de modo que se cumplen sin importar qué programa escriba los datos:

- formatos de identificadores y huellas;
- rangos de puntajes y años;
- coherencia entre fechas;
- coherencia entre país y municipio;
- valores permitidos;

- existencia en los catálogos;
- prohibición de fechas futuras;
- correspondencia entre la captura y el perfil.

El repositorio incluye 20 pruebas automáticas que intentan insertar datos inválidos y verifican que la base los rechace, y 25 pruebas unitarias de las reglas de verificación y normalización y del analizador del *scraping*. Todas se superan.

Registro de datos faltantes. Los campos solo pueden quedar vacíos donde el diccionario de datos lo permite. Cada vacío relevante genera una incidencia (información incompleta o no verificable), y una vista de completitud resume, por egresado, cuántos programas, experiencias y clasificaciones completas tiene y cuántos días lleva sin actualizarse.

Trazabilidad de las fuentes. Toda formación y experiencia referencia su captura; la captura, su canal y su ejecución; y las tablas versionadas conservan cada cambio con su periodo de vigencia.

Datos de prueba

Para demostrar el funcionamiento se construyeron 10 casos ficticios: 8 perfiles que simulan la salida del *scraper* (canal A), una exportación del canal B y un perfil inscrito en la lista de exclusión. Se agregó además un resultado de búsqueda que no corresponde a un perfil. Cada caso ejercita al menos una regla (Tabla 19). Todos los nombres, URL y organizaciones son inventados.

Tabla 19

Datos de prueba y resultados

Caso	Canal	Situación simulada	Resultado del proceso
Ana María Rojas Pérez	A	Enlace a la página oficial; pregrado y maestría de Sistemas; tres cargos con progresión	Aceptada (100 puntos); dos programas; tres experiencias clasificadas
Ana Maria Rojas Perez (segunda cuenta)	A	La misma persona con otra cuenta, sin tildes y con «Ing. Sistemas»	Aceptada (90); posible duplicado de la anterior; la fusión une ambos registros
Carlos Andrés Gómez Salazar	A	Ingeniería Civil; entidad pública; empleo de tiempo completo antes de terminar	Aceptado (95); sector O; incidencia de inconsistencia
Valentina Herrera Castro	A	Título en inglés; trabaja en Alemania; maestría en curso en el exterior	Aceptada (95); país DE, ciudad Hamburgo; posgrado externo en curso
Julián Moreno Díaz	A	Formación sin años; cargo «Key Account Associate»; empresa mal escrita	Por revisar (75); no verificable; cargo incompleto; posible duplicado de organización
Daniela Torres Vargas	A	Captura de marzo de 2024	Aceptada (100); incidencia de desactualización
Santiago López Ramírez	B	Exportación con fecha de nacimiento y dirección; fundador de una empresa	Aceptado (95); los datos sensibles se descartan; vínculo de emprendimiento
Mariana Castillo Ortiz	A	Estudiante con finalización prevista en 2027	Excluida; solo se conserva la huella
Laura Medina	A	Egresada de la Facultad de Minas, Sede Medellín	Excluida por otra sede
Pedro Álvarez	A	Solicitó la exclusión de sus datos	Bloqueado desde el descubrimiento; nunca se captura

En la primera ejecución, el proceso identificó y consolidó siete egresados: seis los aceptó automáticamente y uno lo envió a revisión manual por tener un puntaje intermedio. Los filtros funcionaron como se esperaba: separaron correctamente a un estudiante y a un egresado de otra sede, respetaron la solicitud de exclusión de un titular y omitieron una URL que no correspondía a un perfil. La estandarización clasificó automáticamente 12 de los 13 cargos. El control de calidad detectó las diez situaciones que se incluyeron a propósito en los datos de prueba: dos posibles duplicados, cuatro registros incompletos, uno ambiguo, uno no verificable, uno

desactualizado y una inconsistencia de fechas. Cada una quedó registrada para su revisión. Por último, al repetir la ejecución no se creó ningún registro adicional. Los perfiles consultados hace menos de 90 días no se volvieron a solicitar, y la exportación cargada de nuevo se reconoció como «sin cambios». Esto confirma que el proceso es idempotente y que puede ejecutarse de forma periódica sin duplicar información.